

Combien vaut une voiture d'occasion ?

Prédire le prix de revente par régression linéaire


Hafssa El Hdour • Thibaud Crotta • Nathan Barbier

Juin 2026

Introduction to Data Processing — MAM3, Université Côte d'Azur

Notre but : mettre un prix juste sur une voiture d'occasion


- **Question métier** : **estimer le prix de revente** d'une voiture d'occasion à partir de ses caractéristiques (âge, kilométrage, cylindrée).
- **Utilité** : juger si un prix affiché est **cohérent avec le marché** — le cœur d'un site d'annonces.
- **Cible** = **le prix**, une grandeur **continue** (de quelques centaines à $>100\,000$ €).
- $\Rightarrow$ le bon outil est la **régression linéaire** (pas logistique = binaire, ni softmax = classes).



Le prix est **continu** et étalé : c'est lui qu'on prédit.

71 593 voitures réelles, 10 variables, un prix à prédire


- **71 593 voitures** × **10 variables** — vraies annonces d'occasion (UK, 7 marques).
- **Cible, le prix** : moyenne $\approx 16\,580$ €, de **495 €** à **145 000 €** (forte asymétrie).
- **Variables** : 5 numériques (âge, kilométrage, cylindrée, conso, taxe) + 4 catégorielles (marque, modèle, boîte, carburant) $\Rightarrow$ **One-Hot** (catégories non ordonnées).
- **Nettoyage** : 842 doublons retirés (72 435 $\rightarrow$ 71 593); Electric (5 véh.) $\rightarrow$ Other; âge = 2026—année; **0** manquant.



Variables **catégorielles** : marque, carburant, boîte
 $\Rightarrow$ encodées en One-Hot.

Une feature maison qui change tout : cylindrée ÷ âge


- **Idée** : combiner deux variables comme le suggèrent les nuages de points (interactions).
- **cylindree_sur_age** = cylindrée / (âge + 1) : capte l'interaction **motorisation** × **jeunesse** — un gros moteur *sur une voiture récente* se vend cher, ce que ni la cylindrée ni l'âge ne voient *seuls*.
- **Comment on la juge** : au **gain de R^2 en validation croisée** (5-fold), pas à la taille du coefficient. $\Rightarrow R^2 = 0,64$ à elle seule, **+0,07** ajoutée au modèle (la meilleure, de loin).
- **Sélection** : km_par_an **écartée** (corrélée **0,96** au kilométrage $\Rightarrow$ redondante).



Gain de R^2 (validation croisée) :
cylindree_sur_age domine largement.

On prédit le prix à 80 % — et c'est stable

- **Modèle** : régression linéaire multiple — choisie car la cible est **continue** et ses coefficients sont **interprétables** (en €).
- **Variables** : numériques (âge, kilométrage, cylindrée, conso) + One-Hot (boîte, carburant) + la feature maison cylindree_sur_age.
- **Validation** : holdout **80/20** et validation croisée **5-fold** (on vérifie la stabilité).
- **Résultats** : $R^2_{\text{test}} = 0,80$ · RMSE = 4 188 € · MAE = 2 763 €.
- **Fiable ?** CV = $0,72 \pm 0,04$ ⇒ **pas de surapprentissage**.



Réel vs prédit : points alignés sur la diagonale
($R^2 = 0,80$).

Ce qu'on retient — et comment aller plus loin

- **Bilan** : un modèle **simple** explique déjà **~80 %** de la variance du prix sur des voitures jamais vues, avec des leviers de **bon sens** — cylindrée $\uparrow$, âge et kilométrage $\downarrow$.
- **Bénéfice métier** : de quoi estimer un prix juste et repérer une bonne affaire, comme le ferait un site d'annonces.
- **Pistes d'amélioration** :
 - **Modéliser** $\log(\text{prix})$: corrige la forte asymétrie $\Rightarrow$ plus de prédictions négatives et meilleur sur les voitures chères.
 - **Standardiser** les variables : coefficients comparables $\Rightarrow$ importance vraiment lisible.
 - **Ajouter la marque** (One-Hot, 7 modalités) : premium vs généraliste.
- **Leçon transverse** : notre 1^{er} dataset (santé mentale) n'expliquait rien car **synthétique** ($|r|_{\max} \approx 0,04$) ; un dataset **réel**, lui, raconte une histoire.

Merci !

Des données *réelles* racontent une histoire.