

Combien vaut une voiture d'occasion ?

Rapport — *Introduction to Data Processing* (MAM3, 2025-2026)

Hafssa El Hdour • Thibaud Crotta • Nathan Barbier

Université Côte d'Azur — Polytech Nice Sophia • Juin 2026

Dépôt Git : <https://github.com/barbiernathan2005/PROJET-DATA-SCIENCE>

Jeu de données : *UK Used Cars* (Kaggle) — 7 marques d'occasion fusionnées.

1 Business goal

Tout est parti d'une question banale, de celles qu'on se pose en faisant défiler des annonces le soir : combien vaut, au juste, une voiture d'occasion ? Peut-on deviner son prix de revente à partir de ce que l'on sait d'elle, son âge, ses kilomètres, sa cylindrée, sa boîte de vitesses ? La question n'a rien de théorique. C'est même le calcul que fait un site d'annonces chaque fois qu'il vous signale une « bonne affaire ». Y répondre rend service des deux côtés du marché : à l'acheteur qui a peur de payer trop cher, comme au vendeur qui cherche le prix juste.

Seulement, pour en arriver là, nous avons fait un détour, et c'est sans doute ce qui nous a le plus appris. Notre premier jeu de données, *Global_Mental_Health_Dataset_2025* (2 500 lignes), portait sur la santé mentale, et nous voulions savoir si le stress se devinait à partir du sommeil. À première vue, il avait tout pour plaire : propre, complet, sans une seule valeur manquante. Trop beau, en réalité.

Le doute est né en traçant la matrice de corrélation (Figure 1). Nous nous attendions à voir quelques liens se dessiner ; il n'y avait rien. Pas une seule paire de variables ne se répondait : la corrélation la plus forte plafonnait à $|r| = 0,04$, et le couple sommeil–stress, que l'on imaginait pourtant évident, tombait à $-0,01$. Or, dans la vie réelle, le sommeil et le stress vont toujours un peu de pair. Une matrice aussi plate, où absolument tout vaut zéro, ne s'observe pour ainsi dire jamais sur de vraies mesures. C'est au contraire exactement ce que l'on obtient lorsque chaque colonne a été tirée dans son coin, au hasard : la marque de fabrique de données générées artificiellement, par une IA.

Avant d'accuser le jeu de données, nous avons tout de même voulu en avoir le cœur net. Nous n'avons pas regardé que la corrélation de Pearson, qui ne capte que les liens en ligne droite, mais aussi celle de Spearman, qui détecte les liens même lorsqu'ils sont courbes : zéro des deux côtés, donc rien ne nous échappait. Nous avons aussi passé en revue toutes les colonnes numériques, et pas seulement celles qui nous arrangeaient, pour ne pas nous mentir à nous-mêmes. La conclusion s'est imposée d'elle-même : ces données ne mesuraient rien, elles avaient été fabriquées. La leçon, elle, nous a accompagnés jusqu'au bout du projet : avant de se lancer dans la moindre analyse, on vérifie d'où viennent les données, et si elles sont réelles.

Nous avons donc tout repris, cette fois avec un jeu de données bien réel : *UK Used Cars*, de vraies annonces de voitures d'occasion au Royaume-Uni, réparties sur sept marques (Audi, BMW, Ford, Hyundai, Skoda, Toyota, Volkswagen). Le contraste a été immédiat : des relations nettes, exploitables, et même quelques imperfections, des doublons et des valeurs extrêmes, qui loin de nous gêner prouvaient que nous avions enfin affaire à du vrai.




FIGURE 1 – Notre premier jeu de données, sur la santé mentale, finalement abandonné. Sa matrice de corrélation est entièrement « éteinte » : toutes les cases valent à peu près zéro ($|r| \text{ max} = 0,04$). Sur de vraies mesures, quelques liens ressortiraient forcément ; ici, leur absence totale trahit des données fabriquées.

2 Team management

Nous étions trois, et nous avons assez vite compris que le plus efficace était de jouer sur les points forts de chacun plutôt que de tout faire à trois sur chaque tâche. Chacun a donc pris la responsabilité d'un pan du projet, sans pour autant travailler dans son coin : les décisions importantes, à commencer par celle, lourde de conséquences, d'abandonner notre premier jeu de données, ont toujours été prises ensemble.

Membre	Contributions principales
Nathan Barbier	Tri et nettoyage des données, rédaction du rapport
Hafssa El Hdour	Régression et conception des slides
Thibaud Crotta	Variables « maison » (handcrafted features) et visualisations

Concrètement, Nathan s'est chargé du tri et du nettoyage des données, retirer les doublons, traiter les valeurs aberrantes, bref mettre le fichier en état d'être analysé, avant de prendre en main la rédaction de ce rapport. Hafssa a porté la partie régression, le cœur statistique du projet, et conçu les slides de la soutenance. Thibaud, lui, a construit nos variables maison et réalisé l'ensemble des visualisations qui donnent à voir le jeu de données. Les frontières n'étaient pas étanches pour autant : on relisait volontiers le travail des autres, et il n'était pas rare qu'une figure de Thibaud relance une discussion sur le modèle d'Hafssa.

Côté organisation, tout est passé par GitHub. Le dépôt nous a servi de point de ralliement : chacun y déposait son code, ses figures et ses textes, ce qui nous évitait de nous renvoyer des fichiers par mille canaux et de nous emmêler entre les versions. C'est aussi ce qui nous a permis de garder une trace de notre cheminement, y compris de nos fausses pistes.

Notre planning, justement, a été marqué par un virage. Nous avons d'abord investi du temps sur le jeu de données « santé mentale », avant de devoir tout reprendre une fois sa nature artificielle découverte. Plutôt que de le regretter, nous l'avons assumé : ce détour nous a coûté quelques jours, mais il fait partie de notre démarche et nous a beaucoup appris. La suite s'est enchaînée plus sereinement : exploration et nettoyage du nouveau jeu de données, puis visualisations et création de variables, ensuite la régression et sa validation, et enfin la mise en forme finale, le rapport d'un côté, les slides de l'autre.

3 Data visualisation

3.1 De la donnée brute à la donnée exploitable

Avant la moindre figure, il a fallu rendre le jeu de données utilisable. Le fichier brut compte 72 435 annonces et 10 colonnes : le modèle, l'année, le prix, la transmission, le kilométrage, le carburant, la taxe, la consommation (mpg), la cylindrée et la marque. Nous avons commencé par renommer les colonnes en français pour la lisibilité, supprimer une colonne d'index parasite, et surtout remplacer l'année de mise en circulation par un *âge* ($= 2026 - \text{année}$), bien plus parlant pour notre question.

Le nettoyage proprement dit a retiré 842 annonces strictement identiques, ramenant le total à 71 593 voitures. Nous avons aussi posé un garde-fou contre les âges aberrants (négatifs ou supérieurs à 40 ans) ; comme les millésimes s'échelonnent ici de 1996 à 2020, aucune ligne n'a finalement été écartée à ce titre, mais le filtre reste en place par prudence. Enfin, la catégorie « Electric », qui ne comptait que 5 véhicules, a été fondue dans « Other » : cinq exemples, c'est bien trop peu pour qu'un modèle en apprenne quoi que ce soit.

Bonne surprise pour un jeu de données réel, il ne contenait aucune valeur manquante. Nous avons malgré tout documenté une stratégie d'imputation — médiane pour les variables numériques, mode pour les catégorielles — qui se serait appliquée si des trous étaient apparus. Restait l'encodage des variables catégorielles : nous avons retenu un *One-Hot Encoding* (en supprimant une modalité de référence) pour la transmission et le carburant, parce que ce sont des catégories sans ordre naturel ; un simple encodage numérique aurait laissé croire au modèle qu'« automatique » est plus grand que « manuelle ». La variable modèle, avec ses 146 valeurs distinctes, a en revanche été écartée : la passer en One-Hot aurait fait exploser le nombre de colonnes, ce qu'on appelle le fléau de la dimensionnalité.

3.2 Exploration visuelle

Une fois les données propres, nous avons pris le temps de les regarder en face avant de modéliser quoi que ce soit. C'est l'étape qu'on est le plus tenté de sauter, et c'est sans doute celle qui nous a le plus servi : on ne construit pas un modèle solide sur des variables qu'on n'a pas d'abord comprises. Toutes les figures qui suivent ont été produites avec **pandas**, **matplotlib** et **seaborn**.

La première chose à observer, c'est la variable que l'on cherche justement à prédire, le prix (Figure 2). Sa distribution est très asymétrique : la grande majorité des voitures se concentre entre 8 000 et 20 000 €, avec un pic net autour de 10 000 €, tandis qu'une fine traîne s'étire loin vers la droite, jusqu'à des modèles à plus de 140 000 €. Le prix moyen, environ 16 580 €, se retrouve ainsi tiré vers le haut par une poignée de voitures de luxe, là où le gros du marché reste bien plus modeste. Cette asymétrie n'est pas un simple détail esthétique : elle annonce d'emblée que les voitures chères, rares et atypiques, seront les plus difficiles à estimer.

Nous avons ensuite regardé de quoi notre jeu de données est réellement composé (Figure 3). Du côté des marques, Ford et Volkswagen sont de loin les plus représentées, suivies d'Audi et BMW, tandis que Hyundai, Skoda et Toyota restent plus discrètes. Côté motorisation, l'essence et le diesel se partagent l'écrasante majorité du parc, l'hybride demeurant marginal. Enfin, la boîte manuelle domine largement, devant les boîtes automatiques et semi-automatiques. Ces déséquilibres ne sont pas neutres : un modèle apprendra forcément mieux à estimer une Ford essence à boîte manuelle, omniprésente, qu'une hybride dont il n'a vu que quelques exemples.

Restait à mesurer quelles variables pèsent vraiment sur le prix. La matrice de corrélation (Figure 4) résume tous ces liens d'un seul coup d'œil. Parmi les variables brutes, la cylindrée ressort comme la meilleure alliée du prix (+0,63) : une grosse motorisation se revend cher. À l'inverse, l'âge (-0,52) et le kilométrage (-0,43) tirent le prix vers le bas, exactement comme le veut l'intuition de la décote ; la consommation (mpg, -0,33) et la taxe (+0,35) jouent un




FIGURE 2 – Distribution du prix de revente. Fortement asymétrique à droite : un pic autour de 10 000 €, et une longue traîne de voitures haut de gamme qui s’étend jusqu’à 145 000 €.




FIGURE 3 – Composition du jeu de données selon trois variables catégorielles. Ford et Volkswagen dominent côté marque ; l’essence et le diesel écrasent les autres motorisations ; la boîte manuelle est majoritaire. Le parc est donc déséquilibré, ce dont il faut tenir compte.

rôle plus secondaire. Deux points méritent qu’on s’y arrête. D’abord, l’âge et le kilométrage sont eux-mêmes très liés ($+0,75$) — une voiture ancienne a logiquement roulé davantage —, ce dont il faudra se méfier au moment de la régression. Ensuite, une variable sort déjà nettement du lot, avec une corrélation de $+0,85$: `cylindree_sur_age`. Elle ne figure pas dans le jeu de données d’origine : c’est une variable que nous avons fabriquée nous-mêmes. Nous expliquons en Section 4 comment, et pourquoi elle fonctionne aussi bien.

Enfin, le prix change nettement d’une marque à l’autre (Figure 5). Audi et BMW affichent les médianes les plus hautes, autour de 20 000 €, et surtout de longues traînes de valeurs extrêmes qui grimpent jusqu’à 120 000–145 000 € : ce sont ces modèles qui peuplaient le sommet de la distribution vue plus haut. Ford, Toyota, Skoda et Hyundai forment au contraire un groupe plus accessible, avec des médianes autour de 11 000–13 000 €. Cette figure rend aussi visible un point crucial pour la suite : la nuée de points isolés tout en haut, ces voitures hors normes que la régression aura le plus grand mal à suivre.

Ces quelques figures nous ont donné une véritable carte du terrain : une cible asymétrique, des variables aux effets clairs, une marque qui compte, et déjà l’indice qu’en combinant deux variables on peut faire mieux que chacune prise isolément. C’est précisément le sujet de la section suivante.




FIGURE 4 – Matrice de corrélation des variables numériques. La cylindrée est le meilleur prédicteur brut du prix (+0,63), devant l’âge et le kilométrage qui le font baisser. La variable `cylindree_sur_age`, que nous avons construite, atteint déjà +0,85 — on y revient en Section 4.

4 Handcrafted features

L’ingénierie des caractéristiques (*feature engineering*) consiste à fabriquer de nouvelles variables à partir de celles dont on dispose déjà, pour donner au modèle de quoi voir ce qu’il ne percevait pas. Dans notre cas, la meilleure trouvaille n’est pas sortie d’une formule, mais d’un graphe.

4.1 Une idée née d’une figure

Nous savions déjà, depuis la matrice de corrélation, que la cylindrée tirait le prix vers le haut et que l’âge le tirait vers le bas. Mais ces deux effets, pris séparément, ne disaient pas tout. La vraie idée nous est venue en les regardant *ensemble*, sur un même graphe (Figure 6).

Le principe de cette figure est simple : l’âge se lit en abscisse, la cylindrée en ordonnée, et chaque point — une combinaison âge–cylindrée — est coloré selon son prix, du bleu (bon marché) au rouge (cher). En la parcourant du regard, un motif se dessine. À cylindrée fixée, si l’on se déplace vers la droite (des voitures de plus en plus vieilles), les couleurs se refroidissent : le prix chute. À âge fixé, si l’on monte (des moteurs de plus en plus gros), les couleurs se réchauffent : le prix grimpe. Surtout, les voitures les plus chères, les plus rouges, se massent toutes dans le coin *haut-gauche* — jeunes *et* puissantes — tandis que les plus bleues occupent le coin *bas-droit* — vieilles *et* petites. Les lignes de même prix ne suivent donc ni l’horizontale ni la verticale : elles courent en *diagonale*. C’est ce détail, cette diagonale, qui a tout déclenché : le prix ne répond pas à l’âge ou à la cylindrée, mais à leur *rapport*.

Restait à traduire cette observation visuelle en une variable. Il nous fallait un seul nombre, grand quand la voiture est à la fois jeune et puissante, petit sinon. Un rapport fait exactement cela : on place la cylindrée au numérateur (plus le moteur est gros, plus le nombre monte) et l’âge au dénominateur (plus la voiture vieillit, plus le nombre redescend). D’où la variable que nous avons construite :

$$\text{cylindree_sur_age} = \frac{\text{cylindrée}}{\text{âge} + 1}.$$

Le « +1 » au dénominateur n’a rien de cosmétique : il évite une division par zéro pour une voiture neuve (âge = 0) et empêche le ratio d’exploser pour les véhicules les plus récents. Un




FIGURE 5 – Prix selon la marque. Coupure nette entre les marques premium (Audi, BMW, médiane $\approx 20\,000$ €) et les généralistes (Ford, Toyota, Hyundai, $\approx 11\,000$ €). Les nombreux points au-dessus des moustaches sont les valeurs extrêmes qui mettront le modèle en difficulté.

exemple rend la chose concrète : un moteur de 2,0 L sur une voiture de 2 ans vaut $2,0/3 \approx 0,67$, alors que le *même* moteur sur une voiture de 14 ans tombe à $2,0/15 \approx 0,13$, soit cinq fois moins. La variable sépare ainsi une sportive récente d’une ancienne au moteur identique — exactement la diagonale que nous avait montrée la figure.

Par curiosité, et pour être sûrs de ne rien manquer, nous avons poussé l’exploration plus loin encore, en affichant trois variables à la fois — âge, kilométrage et cylindrée — le prix toujours rendu par la couleur, soit quatre dimensions sur un même graphique (Figure 7). La même tendance s’y retrouve, les teintes chaudes se concentrant du côté des voitures jeunes et puissantes. Mais en trois dimensions, les points se masquent les uns les autres et l’œil peine à suivre : la vue en deux dimensions est restée, de loin, la plus lisible, et c’est elle qui nous a réellement guidés. Une bonne figure qui se lit vaut mieux qu’une figure spectaculaire qu’on ne déchiffre pas.

4.2 Construire, tester, puis choisir

Une intuition, aussi séduisante soit-elle, ne suffit pas : encore faut-il vérifier qu’elle apporte vraiment quelque chose. Nous n’avons donc pas créé une seule variable, mais cinq, toutes inspirées des interactions repérées sur les graphes, avant de les mettre à l’épreuve (Tableau 1).

Variable construite	Formule	R^2 seule	Gain au modèle
cylindree_sur_age	cylindrée / (âge+1)	0,64	+0,070
km_fois_age	kilométrage $\times$ âge	−0,08	+0,024
age_carre	âge ²	−0,02	+0,024
cylindree_fois_age	cylindrée $\times$ âge	−0,22	+0,023
mpg_sur_age	mpg / (âge+1)	−0,26	+0,002

TABLE 1 – Les cinq variables construites et testées. La colonne « R^2 seule » donne le pouvoir explicatif de chaque variable prise isolément (en validation croisée), la dernière le gain qu’elle apporte une fois ajoutée au modèle de base. `cylindree_sur_age` écrase les autres sur les deux critères.




FIGURE 6 – Prix (en couleur) selon l'âge et la cylindrée. Le dégradé suit une diagonale : les voitures jeunes à grosse cylindrée (en haut à gauche) sont les plus chères, les vieilles à petite cylindrée (en bas à droite) les moins chères. C'est ce graphe qui nous a soufflé l'idée d'une variable combinant les deux, `cylindree_sur_age`.

Le point de méthode qui nous tient à cœur est là : on ne juge pas une variable à la *taille de son coefficient* dans la régression — ce coefficient dépend de l'échelle de la variable et n'a donc rien d'une mesure d'utilité. On la juge à ce qu'elle fait *gagner* au modèle. Pour chaque candidate, nous avons donc mesuré le R^2 en validation croisée à 5 plis (la méthode est détaillée dans la partie consacrée à la régression), à la fois seule et ajoutée au modèle de base, puis comparé les gains (Figure 8). D'ailleurs, plusieurs candidates affichent un R^2 *négligable* prises seules — pire que de prédire bêtement le prix moyen — ce qui montre bien qu'une variable peut sembler intéressante sans rien apporter une fois mise à l'épreuve.

Le verdict est sans appel : `cylindree_sur_age` domine largement, avec un gain de $+0,07$ de R^2 , près de trois fois celui de la meilleure des autres candidates. Repérée dès la matrice de corrélation (Figure 4, $+0,85$ avec le prix), elle se confirme à l'épreuve des chiffres : à elle seule, en validation croisée, elle explique déjà 64 % de la variance du prix, là où la cylindrée brute plafonne à 25 %. Ajoutée au modèle, elle le fait passer de 0,65 à 0,72 de R^2 . Sa force tient à ce qu'elle capture en une seule colonne l'interaction *motorisation* $\times$ *jeunesse*, que ni l'âge ni la cylindrée ne voyaient séparément.

La même rigueur nous a conduits, à l'inverse, à *écarter* une variable. Nous avons aussi fabriqué un kilométrage annuel moyen ($\text{kilométrage} / (\text{âge} + 1)$) ; mais il s'est révélé corrélé à 0,96 avec le kilométrage brut — une quasi-copie, qui n'apportait aucune information nouvelle et risquait surtout d'introduire de la colinéarité. Nous l'avons donc supprimé. Garder ce qui aide, retirer ce qui fait doublon : c'est une forme simple de sélection de variables, alternative légère à une réduction de dimension de type ACP.




FIGURE 7 – La même exploration poussée à trois variables (âge, kilométrage, cylindrée), le prix toujours en couleur — quatre dimensions d’un coup. Spectaculaire mais peu lisible : c’est la vue 2D (Figure 6) qui nous a vraiment guidés.




FIGURE 8 – Gain de R^2 (validation croisée 5-fold) apporté par chaque variable construite lorsqu’on l’ajoute au modèle de base. `cylindree_sur_age` se détache nettement (+0,069), environ trois fois plus que la meilleure des autres candidates.

5 Linear regression

5.1 Pourquoi une régression linéaire ?

Le choix du modèle découle directement de ce que l’on cherche à prédire. Notre cible, le prix, est une grandeur *numérique continue* qui s’étend de quelques centaines à plus de cent mille euros. C’est exactement le terrain d’une *régression linéaire* : on cherche à exprimer le prix comme une combinaison pondérée des caractéristiques de la voiture. Les deux autres familles vues en cours ne conviendraient pas ici : la régression *logistique* prédit une réponse binaire (oui/non), et la régression *softmax* range les individus dans plusieurs catégories. Ni l’une ni l’autre ne sait produire un montant en euros.

Concrètement, notre modèle est une régression linéaire *multiple* : il combine toutes les variables retenues au fil des étapes précédentes — l’âge, le kilométrage, la cylindrée et la consommation, les versions One-Hot de la transmission et du carburant, et bien sûr notre variable maison `cylindree_sur_age`. Il estime le prix sous la forme

$$\widehat{\text{prix}} = \beta_0 + \beta_1 \text{âge} + \beta_2 \text{kilométrage} + \beta_3 \text{cylindrée} + \beta_4 \text{mpg} + \beta_5 \text{cylindree_sur_age} + \sum_k \gamma_k d_k,$$

où les d_k sont les indicatrices One-Hot et où chaque coefficient mesure l'effet d'une variable, toutes choses égales par ailleurs. L'apprentissage, mené avec `scikit-learn`, consiste à choisir les coefficients qui rapprochent le plus possible les prix prédits des prix réels.

5.2 Ce que le modèle a retenu

Une fois le modèle entraîné, on peut examiner le poids qu'il accorde à chaque variable (Figure 9). Sans surprise après la section précédente, `cylindree_sur_age` domine très largement : c'est, et de loin, le principal levier du prix. Une précaution s'impose toutefois pour lire ce graphe. Comme cette variable est *construite* à partir de l'âge et de la cylindrée, ces deux-là se retrouvent en partie redondantes avec elle, et leur coefficient individuel devient difficile à interpréter : la cylindrée brute ressort même avec un signe négatif, et l'âge avec un signe positif, ce qui semble contre-intuitif. Ce n'est pas une erreur, mais un effet classique de *colinéarité* : quand des variables se recoupent, le modèle répartit leur influence entre elles de façon parfois déroutante. La leçon rejoint celle de la section précédente : ce graphe se lit comme une *hiérarchie d'importance*, pas comme une liste d'effets isolés.




FIGURE 9 – Importance des variables (coefficients standardisés). `cylindree_sur_age` écrase toutes les autres. Les signes de la cylindrée (négatif) et de l'âge (positif), contre-intuitifs, traduisent la colinéarité entre ces variables et la variable construite à partir d'elles : on lit ce graphe comme un classement d'importance, pas comme des effets isolés.

5.3 Les résultats sont-ils fiables ?

Pour juger le modèle, nous l'avons évalué de deux façons complémentaires. D'abord un *holdout* : on entraîne sur 80 % des voitures et on teste sur les 20 % restantes, que le modèle n'a jamais vues. Ensuite une *validation croisée à 5 plis*, qui répète l'opération cinq fois sur des découpages différents et moyenne les scores, afin de s'assurer que la performance ne tient pas à un découpage chanceux.

Le modèle explique environ 80 % de la variance du prix sur le jeu de test, avec une erreur moyenne (MAE) de l'ordre de 2760 € — ce qui n'est pas si mal pour des voitures qui valent en moyenne 16580 €. La validation croisée, plus prudente, donne un R^2 moyen de 0,72 (à $\pm 0,04$ près) : l'écart avec le 0,80 du test montre que ce découpage-là nous était un peu favorable, mais la stabilité des cinq plis confirme l'absence de surajustement marqué. On peut donc retenir un pouvoir explicatif solide, de l'ordre de 0,72 à 0,80.

Indicateur	Valeur
R^2 (jeu de test, holdout 80/20)	0,80
RMSE (jeu de test)	4 188 €
MAE (jeu de test)	2 763 €
R^2 (validation croisée 5-fold)	$0,72 \pm 0,04$

TABLE 2 – Performance du modèle final, mesurée sur des données que le modèle n’a pas servi à entraîner.

Reste à savoir *où* le modèle se trompe, et la Figure 10 le dit sans détour. Tant que les voitures restent sous environ 40 000 €, les prédictions s’alignent bien sur la diagonale idéale. Au-delà, le modèle *sous-estime systématiquement* : les voitures les plus chères, jusqu’à 140 000 €, sont prédites autour de 70 000 € seulement, comme s’il butait sur un plafond. On retrouve là le problème annoncé dès la première section : ces véhicules de luxe sont trop rares et trop atypiques pour que le modèle apprenne à les suivre. Plus gênant encore, quelques prédictions tombent même *en dessous de zéro* — un prix négatif n’a aucun sens, mais rien n’empêche mathématiquement une droite de passer sous l’axe. Ces deux limites, sous-estimation du haut de gamme et prédictions négatives, dessinent naturellement les pistes d’amélioration que nous abordons en conclusion.




FIGURE 10 – Prix prédit en fonction du prix réel sur le jeu de test ; la diagonale rouge représente la prédiction parfaite. L’ajustement est bon dans le gros du marché, mais le modèle plafonne et sous-estime les voitures les plus chères, et produit même quelques prix négatifs en bas à gauche.

6 Conclusion

Au terme de ce projet, nous disposons d’un modèle capable d’estimer le prix d’une voiture d’occasion à partir de ses seules caractéristiques, en se trompant en moyenne d’environ 2 760 € et en expliquant entre 72 et 80 % de la variation des prix. Pour notre question de départ, c’est amplement suffisant : le modèle sait dire si une annonce est à un prix cohérent avec le marché, et de quel côté elle penche. Et au fond, la principale leçon n’est pas tant le chiffre obtenu que la démarche : c’est en *regardant* nos données — d’abord pour démasquer un premier jeu fabriqué de toutes pièces, ensuite pour y lire l’interaction qui a donné notre meilleure variable — que nous avons le plus appris.

Peut-on faire mieux ? Sans aucun doute, et ce sont nos propres limites qui montrent la voie. Une première piste serait de *recentrer le modèle sur le cœur du marché*, en ne gardant par exemple que les voitures sous 40 000 €. C'est justement au-delà de ce seuil que les prédictions dérapent, et ces véhicules de luxe ne représentent qu'une infime minorité des annonces : en renonçant à les couvrir, on gagnerait nettement en précision là où se trouvent l'immense majorité des acheteurs et des vendeurs. Le compromis est raisonnable, à condition d'assumer que le modèle ne vaut alors que pour ce segment.

Une seconde piste, plus élégante, serait de passer le prix — et les variables les plus asymétriques — au *logarithme*, autrement dit d'ajuster la régression en échelle log-log. Notre cible est si étirée vers le haut qu'une droite peine à la suivre ; en travaillant sur son logarithme, on comprime cette traîne, la relation redevient plus linéaire et l'on gagnerait probablement quelques points de R^2 . Surtout, cette transformation réglerait d'un coup l'absurdité des prix négatifs : l'exponentielle qui ramène du logarithme au prix est toujours positive, si bien qu'un tel modèle ne pourrait, par construction, jamais prédire un prix en dessous de zéro.

On pourrait enfin ajouter la marque au modèle — en One-Hot, ses sept modalités restent raisonnables —, elle qui pesait visiblement sur le prix sans jamais entrer dans la régression finale. Aucune de ces pistes n'était indispensable pour éclairer notre question de départ, mais toutes rappellent qu'un modèle n'est jamais tout à fait fini : il se discute, se critique et s'améliore — ce qui est peut-être, au fond, le vrai sujet de ce cours