

Le stress se lit-il dans notre mode de vie ?

Rapport — *Introduction to Data Processing* (MAM3, 2025-2026)

Hafssa • Thibaud • Nathan

Université Côte d’Azur — Polytech Nice Sophia

Dépôt Git : <https://github.com/barbiernathan2005/PROJET-DATA-SCIENCE>

Dataset : *Lifestyle & Wellbeing Data* — Kaggle (ydatat), enquête Authentic-Happiness.

1 Business goal

Quel est notre dataset ? Pourquoi est-il utile ?

Notre projet répond à une question simple et universelle : **quels facteurs de notre mode de vie sont liés à notre niveau de stress quotidien ?** Comprendre cela a une valeur concrète pour les applications de bien-être, les programmes de prévention santé et la qualité de vie au travail : si l’on identifie des leviers actionnables (sommeil, congés, méditation...), on peut formuler des recommandations utiles.

Notre parcours a commencé par un **échec instructif**. Notre premier dataset (*Global_Mental_Health_Dataset*, **2 500 lignes**), sur la « santé mentale », semblait idéal pour notre toute première problématique — *peut-on prédire le stress à partir du sommeil ?* Mais à l’analyse, **aucune variable n’était corrélée à une autre** : la corrélation maximale (hors diagonale) entre toutes les variables numériques ne valait que $|r| \approx 0,04$, et le couple sommeil $\leftrightarrow$ stress tombait à $-0,02$ (Figure 1). En enquêtant, nous avons compris que ces données étaient **générées artificiellement**, pas mesurées : elles ne pouvaient rien nous apprendre. Nous avons aussi constaté que tout le thème « stress / burnout » sur Kaggle est saturé de jeux de données synthétiques. Première leçon, devenue notre fil rouge : *vérifier la provenance et la réalité des données avant toute analyse*.

Nous avons alors choisi un jeu de données **réel** : l’enquête *Lifestyle & Wellbeing* d’Authentic-Happiness, soit **15 971 réponses authentiques** collectées dans le monde (2015-2020). Chaque répondant a renseigné ses habitudes de vie et son niveau de stress quotidien. Contrairement au premier dataset, ces données présentent de vraies relations exploitables — et les imperfections typiques du réel (une valeur erronée à corriger), gage d’authenticité.

2 Team management

Comment travaillons-nous ? Quel est notre planning ?

Nous sommes une équipe de **3 personnes**, coordonnée via un **dépôt Git** partagé.

Répartition des rôles :

- **Hafssa** — **Données & nettoyage** : chargement, sanity checks, encodage des catégories, gestion des valeurs manquantes.
- **Nathan** — **Visualisation & features maison** : figures, conception et justification des indices, vérification de leur pertinence.
- **Thibaud** — **Modélisation & storytelling** : régression, validation croisée, interprétation, rédaction du récit et des slides.




FIGURE 1 – Le dataset abandonné (synthétique). La matrice de corrélation est entièrement « éteinte » (toutes les cases ≈ 0) : c’est la **signature de données fabriquées** — aucune relation exploitable, donc aucune histoire à raconter, exactement l’inverse des données réelles (Figure 2).

Planning (calendrier du cours) :

Jour	Tâche
Lun. 01/06	Définition du problème, choix et chargement des données
Mar. 02/06	Nettoyage, visualisation, première trame de storytelling
Mer. 03/06	Features maison, régression linéaire, itérations
Jeu. 04/06	Pipeline final, préparation de l’oral, dépôt des slides
Ven. 05/06	Soutenance orale + finalisation du rapport

Les décisions importantes (choix du dataset, des features, message clé) ont été prises **collectivement**.

3 Data visualisation

Description. Le dataset contient **15 971 lignes** et **23 variables**. La cible est DAILY_STRESS, un score de stress quotidien de **0 (aucun)** à **5 (très stressé)**, traité comme continu. Les explicatives sont de deux types :

- **~20 variables numériques** de mode de vie : SLEEP_HOURS, DAILY_STEPS, SOCIAL_NETWORK, CORE_CIRCLE, SUPPORTING_OTHERS, WEEKLY_MEDITATION, FLOW, TIME_FOR_PASSION, LOST_VACATION, DAILY_SHOUTING, SUFFICIENT_INCOME, PERSONAL_AWARDS, etc. ;
- **2 variables catégorielles** : AGE (tranches) et GENDER.

Nettoyage (data wrangling). La cible contenait une valeur non numérique ('1/1/00'), forcée en NaN puis retirée (15 971 lignes conservées). AGE et GENDER ont été encodées en **one-hot** (éviter un faux ordre), et toutes les variables **standardisées** (moyenne 0, écart-type 1) pour comparer l’importance des coefficients.

(Choix : des diagrammes en barres triés plutôt qu’un camembert ou un nuage surchargé, car l’œil compare mieux des longueurs que des angles — principe vu en cours.)




FIGURE 2 – Corrélation de chaque variable avec le stress. Barres horizontales triées (rouge = corrélation positive, bleu = négative), axe partant de zéro, palette à deux couleurs. *Lecture* : aucune variable ne domine — les corrélations sont **modérées** —, ce qui motive notre travail de combinaison (section 4). Du côté « stress » ressortent DAILY_SHOUTING et LOST_VACATION ; du côté « apaisement », WEEKLY_MEDITATION, SLEEP_HOURS et SUFFICIENT_INCOME.

4 Handcrafted features

Le constat de la section précédente — aucune variable seule n’est fortement corrélée au stress — nous a conduits à **construire 4 nouvelles variables** combinant les variables brutes selon des hypothèses de bon sens :

1. $\text{SOCIAL_SUPPORT} = \text{CORE_CIRCLE} + \text{SOCIAL_NETWORK} + \text{SUPPORTING_OTHERS}$. *Hypothèse* : le soutien social amortit le stress (Cohen & Wills, 1985).
2. $\text{HEALTHY_HABITS} = \text{SLEEP_HOURS} + \text{DAILY_STEPS} + \text{WEEKLY_MEDITATION} + \text{FRUITS_VEGGIES}$. *Hypothèse* : une même hygiène de vie, dont les comportements se cumulent.
3. $\text{OVERWORK} = \text{LOST_VACATION} + \text{DAILY_SHOUTING} - \text{TIME_FOR_PASSION}$. *Hypothèse* : proxy de surmenage (beaucoup de congés non pris et d’irritabilité, peu de temps pour soi).
4. $\text{SLEEP_x_FLOW} = \text{SLEEP_HOURS} \times \text{FLOW}$. *Hypothèse* : une **interaction** (produit, comme $\text{Pclass} \times \text{Age}$ du cours) : bien dormir **et** être souvent absorbé a un effet protecteur **combiné**.

Vérification de la pertinence (corrélation avec le stress) :

Feature maison	Corrélation	Verdict
OVERWORK	+0,349	✓ le signal le plus fort de toute l’étude
HEALTHY_HABITS	-0,218	✓ pertinent (habitudes saines → moins de stress)
SLEEP_x_FLOW	-0,157	✓ pertinent (l’interaction fonctionne)
SOCIAL_SUPPORT	-0,055	✗ quasi nul — échec instructif

Trois indices sur quatre sont très pertinents — OVERWORK dépasse même toutes les variables brutes. Mais SOCIAL_SUPPORT échoue, et ce résultat est le plus riche d’enseignement.




FIGURE 3 – Coefficients du modèle (variables standardisées) : poids et signe de chaque variable dans la régression. *Lecture* : répond visuellement à la question business — qui fait **monter** ou **baisser** le stress.

En inspectant ses composantes (Figure 3), on voit qu’elles se **contredisent** : un grand réseau social (**SOCIAL_NETWORK**, coef. **+0,09**) et le fait d’aider beaucoup les autres (**SUPPORTING_OTHERS**, **+0,07**) vont de pair avec **plus** de stress — sans doute parce que les personnes très sollicitées socialement sont aussi plus occupées/stressées. En les additionnant avec l’entourage proche, les effets s’annulent. **Leçon** : une feature combinée n’est utile que si ses composantes pointent dans le même sens — la vérification de pertinence sert précisément à le détecter.




FIGURE 4 – Poids des 4 indices maison (coefficients standardisés).

5 Linear / logistic / softmax regression

Choix : la régression linéaire. La cible (DAILY_STRESS, 0-5) est numérique et ordonnée ; nous la traitons comme **continue**. Surtout, notre objectif est l'**explication** (comprendre les leviers) plus que la prédiction parfaite : les coefficients d'une régression linéaire s'**interprètent directement**.

Méthode. $\text{stress} \approx \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k$, coefficients estimés par **moindres carrés** (solution des équations normales $\hat{\beta} = (A^\top A)^{-1} A^\top y$, vue en cours).

Protocole (validation). Découpage **train/test 80-20** ; **standardisation** apprise sur le train ; **validation croisée 5-fold** pour une estimation robuste.

Résultats.

- R^2 (modèle à 23 variables, test) = **0,187**
- R^2 (modèle à 4 indices maison, test) = **0,125** ; en **5-fold** = **0,143 ± 0,013**
- **Font monter** le stress : DAILY_SHOUTING (**+0,32**), LOST_VACATION (**+0,18**), SOCIAL_NETWORK (+0,09), PERSONAL_AWARDS (+0,06).
- **Font baisser** le stress : WEEKLY_MEDITATION (**-0,15**), GENDER_Male (-0,15), SLEEP_HOURS (-0,13), SUFFICIENT_INCOME (-0,12), TIME_FOR_PASSION (-0,09).

Interprétation. Le mode de vie explique environ **15 à 19 % de la variance** du stress. Le facteur le plus fort, DAILY_SHOUTING, est à manier avec prudence : crier/bouder est en partie un **symptôme** du stress, pas seulement une cause (relation quasi-circulaire). Le facteur aggravant le plus **actionnable** est LOST_VACATION (ne pas prendre ses congés). À l'inverse, **méditer, dormir, avoir un revenu suffisant et du temps pour ses passions** sont associés à moins de stress. On note aussi que les hommes déclarent un stress un peu plus faible (GENDER_Male -0,15).

Fiabilité. Le R^2 est **modéré**, ce qui est **attendu et honnête** : le stress est multifactoriel et auto-déclaré. La **stabilité** du 5-fold (écart-type 0,013) indique un modèle **non sur-appris**. Le modèle à 4 indices est un peu moins performant que le modèle complet (0,13 vs 0,19) : c'est le **compromis** interprétabilité / performance — on conserve environ **deux tiers** du pouvoir explicatif avec **5 fois moins** de variables. Nous avons enfin **écarté** WORK_LIFE_BALANCE_SCORE (somme des autres colonnes) pour éviter un R^2 artificiellement parfait (fuite d'information).

6 Conclusion

Bénéfices. L'analyse montre qu'une part du stress quotidien s'**explique par le mode de vie** et désigne des **leviers concrets** : prendre ses congés, méditer, dormir, se garder du temps pour ses passions. Notre feature OVERWORK (surmenage) s'est révélée le **meilleur prédicteur** de toute l'étude (corrélation +0,35).

L'enseignement le plus précieux est venu d'un **échec** : la feature SOCIAL_SUPPORT, pourtant fondée sur la littérature, n'explique rien ici — parce que ses composantes se contredisent dans ces données. Cela rappelle qu'une hypothèse doit toujours être **vérifiée empiriquement**.

Limites : données **auto-déclarées** (biais de perception), cible grossière 0-5, et surtout **corrélation ≠ causalité**.

Améliorations : (i) une **régression ordinale/logistique** adaptée à l'échelle 0-5 ; (ii) revoir SOCIAL_SUPPORT en séparant entourage proche et réseau étendu ; (iii) **segmenter par âge/genre** ; (iv) des données longitudinales pour approcher la causalité.

La vraie leçon du projet : des données *réelles* racontent une histoire — y compris quand elles contredisent nos hypothèses ; des données *fabriquées*, non. Savoir faire la différence est la première compétence du data scientist.

7 List of references

1. **Dataset.** *Lifestyle and Wellbeing Data*, Kaggle (*ydalat*). <https://www.kaggle.com/ydalat/lifestyle-and-wellbeing-data> — enquête « How's Life? The Work-Life Balance survey », www.authentic-happiness.com.
2. **Cours.** L. Fillatre, *Introduction to Data Processing*, Université Côte d'Azur, Polytech Nice Sophia, 2025-2026 (Lectures 1 à 4).
3. **scikit-learn.** Pedregosa et al., *Scikit-learn : Machine Learning in Python*, JMLR 12, 2011. https://scikit-learn.org/stable/modules/linear_model.html
4. **pandas.** McKinney, *Data Structures for Statistical Computing in Python*, 2010.
5. **Visualisation.** C. O. Wilke, *Fundamentals of Data Visualization*, O'Reilly, 2019. <https://clauswilke.com/dataviz/>
6. **Soutien social & stress.** S. Cohen & T. A. Wills, « Stress, social support, and the buffering hypothesis », *Psychological Bulletin*, 98(2), 1985, p. 310-357.