

Combien vaut une voiture d'occasion ?

Rapport — *Introduction to Data Processing* (MAM3, 2025-2026)

Hafssa • Thibaud • Nathan

Université Côte d'Azur — Polytech Nice Sophia

Dépôt Git : <https://github.com/barbiernathan2005/PROJET-DATA-SCIENCE>

Dataset : 100,000 UK Used Car Data (Kaggle) — 7 marques fusionnées.

1 Business goal

Quel est notre dataset ? Pourquoi est-il utile ?

Notre projet répond à une question concrète et universelle : **peut-on prédire le prix d'une voiture d'occasion à partir de ses caractéristiques** ? L'enjeu est réel : un bon modèle aide acheteurs et vendeurs à estimer un prix juste, alimente les plateformes de petites annonces et permet de **repérer les bonnes (et les mauvaises) affaires**.

Notre parcours a commencé par un **échec instructif**. Notre premier dataset (Global_Mental_Health_Data, **2 500 lignes**), sur la « santé mentale », semblait idéal pour notre première problématique — *peut-on prédire le stress à partir du sommeil* ? Mais à l'analyse, **aucune variable n'était corrélée à une autre** : la corrélation maximale (hors diagonale) ne valait que $|r| \approx 0,04$, et le couple sommeil $\leftrightarrow$ stress tombait à $-0,01$ (Figure 1). Ces données étaient **générées artificiellement**, pas mesurées. Première leçon, devenue notre fil rouge : *vérifier la provenance et la réalité des données avant toute analyse*.




FIGURE 1 – Le dataset abandonné (synthétique). La matrice de corrélation est entièrement « éteinte » (toutes les cases ≈ 0) : c'est la **signature de données fabriquées** — aucune relation exploitable.

Nous avons alors choisi un jeu de données **réel** : le dataset *UK Used Cars* (annonces réelles de voitures d'occasion au Royaume-Uni, 7 marques : Audi, BMW, Ford, Hyundai, Skoda, Toyota, Volkswagen). Contrairement au premier, ces données présentent de **vraies relations exploitables** — et les imperfections typiques du réel (années aberrantes, doublons), gage d'authenticité.

2 Team management

Comment travaillons-nous ? Quel est notre planning ?

Nous sommes une équipe de **3 personnes**, coordonnée via un **dépôt Git** partagé.

Répartition des rôles :

- **Hafssa** — **Données & nettoyage** : chargement, sanity checks, années aberrantes et doublons, encodage des catégories.
- **Nathan** — **Visualisation & features maison** : heatmap, boxplots, conception des indices (`car_age`, `mileage_per_year`).
- **Thibaud** — **Modélisation & storytelling** : régression linéaire, évaluation (R^2 /RMSE), interprétation, rédaction du récit et des slides.

Planning (calendrier du cours) :

Jour	Tâche
Lun. 01/06	Définition du problème, 1 ^{er} dataset (santé mentale) → abandon
Mar. 02/06	Choix du dataset réel (voitures), chargement, nettoyage
Mer. 03/06	Features maison, visualisation, régression linéaire
Jeu. 04/06	Évaluation, pipeline final, préparation de l'oral
Ven. 05/06	Soutenance orale + finalisation du rapport

3 Data visualisation

Description. Le dataset contient **72 435 lignes** et **10 variables**. La cible est **price**, le prix de vente en **livres sterling (£)**. Les explicatives sont de deux types :

- **numériques** : `year`, `mileage`, `tax`, `mpg` (consommation), `engineSize` (cylindrée) ;
- **catégorielles** : `model`, `transmission`, `fuelType` et `Make` (marque).

Nettoyage (data wrangling). Deux années manifestement erronées (2060 et 1970) ont été retirées, ainsi que les **doublons** : le dataset passe de **72 435 à 71 593 lignes**. Le carburant **Electric**, très rare, a été regroupé dans **Other**.

(Choix : heatmap + boîtes à moustaches plutôt qu'un camembert, car l'œil compare mieux des positions et des longueurs que des angles — principe vu en cours.)

4 Handcrafted features

Plutôt que d'utiliser l'année brute, nous avons **construit 2 nouvelles variables** plus parlantes :

1. `car_age = 2026 - year`. *Hypothèse* : l'âge est un proxy d'usure ; une voiture plus vieille vaut moins cher. **Corrélation avec le prix** : $-0,52$ (le signal négatif le plus fort).
2. `mileage_per_year = mileage / (car_age + 1)`. *Hypothèse* : le kilométrage **par an** distingue une vieille voiture peu roulée d'une récente très roulée. **Corrélation avec le prix** : $-0,40$. (Le « +1 » évite une division par zéro pour les voitures de l'année.)

Ces deux indices, simples et de bon sens, capturent l'essentiel de l'effet « temps » sur le prix et nourrissent directement la régression.




FIGURE 2 – Heatmap des corrélations (variables numériques). La cylindrée **engineSize** (+0,63) et l'année **year** (+0,52) sont les plus liées au prix; le kilométrage (-0,43) et l'âge (-0,52) le tirent vers le bas.

5 Linear / logistic / softmax regression

Choix : la régression linéaire. La cible (**price**) est une grandeur **numérique continue** : la régression linéaire est le modèle naturel, et ses coefficients s'**interprètent directement** (en £).

Méthode. On prédit **price** à partir de 5 variables : **car_age**, **mileage_per_year**, **engineSize**, **transmission** et **model** (ces deux dernières encodées en nombres avec un **LabelEncoder**). Découpage **train/test 80-20** (**random_state=42**).

Résultats.

- R^2 (test) = **0,735**; R^2 (train) = 0,725 → écart très faible, **pas de surapprentissage**.
- **RMSE (test)** = **4827 £** : l'erreur type de prédiction est d'environ 4800 £.
- **Coefficients** (effet sur le prix) : **engineSize** **+10862 £** par litre de cylindrée (le levier le plus fort); **car_age** **-1695 £** par année d'âge; **transmission** +480 £; **model** +11,5 £; **mileage_per_year** -1,33 £.

Bug corrigé. La première version du code **importait** **r2_score** et **mean_squared_error** sans **jamais s'en servir** : la régression ne mesurait donc ni sa qualité ni son erreur. Nous avons ajouté cette **évaluation** (R^2 + RMSE), qui est le cœur d'un projet de régression. Nous avons aussi remplacé un **chemin de fichier codé en dur** par un chemin relatif (le code tournait seulement sur le PC d'origine).

6 Conclusion

Bénéfices. Un modèle **simple et interprétable** explique déjà **~74 %** de la variance du prix d'une voiture d'occasion. Les leviers sont clairs : une **grosse cylindrée** et une **boîte automatique** font monter le prix; l'**âge** et le **kilométrage** le font baisser. Nos deux features maison (**car_age**, **mileage_per_year**) portent l'essentiel du signal temporel.

L'enseignement le plus précieux est venu d'un **échec** : notre premier dataset, sur la santé mentale, n'avait aucune corrélation (≈ 0) car il était **fabriqué**. Des données réelles racontent une histoire; des données synthétiques, non.




FIGURE 3 – Prix par catégorie. Une **Semi-Auto** (23 483 £) ou **Automatique** (21 315 £) se vend bien plus cher qu’une **Manuelle** (12 520 £) ; côté carburant, **Hybride** (19 048 £) et **Diesel** (18 869 £) devançant l’**Essence** (14 712 £).

Limites : (i) `model` et `transmission` sont encodées en nombres, ce qui impose un **faux ordre** ; (ii) le prix brut rend l’erreur plus grande sur les voitures chères (Figure 4) ; (iii) `marque` et `carburant` ne sont pas (encore) dans le modèle.

Améliorations : (i) **one-hot encoding** des catégories ; (ii) modéliser $\log(\text{prix})$ pour stabiliser la variance ; (iii) ajouter `Make`, `fuelType`, `tax`, `mpg` ; (iv) tester une régression régularisée (Ridge/Lasso).

7 List of references

1. **Dataset.** *100,000 UK Used Car Data set* (7 marques fusionnées), Kaggle. EDA : <https://www.kaggle.com/code/harishkumardatalab/eda-of-multibrand-used-car-dataset> — CSV utilisé (miroir) : https://github.com/Ajinkya017/Car_Dataset
2. **Cours.** L. Fillatre, *Introduction to Data Processing*, Université Côte d’Azur, Polytech Nice Sophia, 2025-2026 (Lectures 1 à 4).
3. **scikit-learn.** Pedregosa et al., *Scikit-learn : Machine Learning in Python*, JMLR 12, 2011. https://scikit-learn.org/stable/modules/linear_model.html
4. **pandas.** McKinney, *Data Structures for Statistical Computing in Python*, 2010.
5. **seaborn.** Waskom, *seaborn : statistical data visualization*, JOSS, 2021. <https://seaborn.pydata.org>




FIGURE 4 – Prix réel vs prédit (jeu de test). Les points suivent globalement la diagonale (prédiction parfaite). Le modèle se disperse davantage sur les voitures les plus chères (la variance du prix augmente avec sa valeur) : une limite connue de la régression linéaire sur des prix bruts.




FIGURE 5 – Coefficients de la régression. La **cylindrée** fait monter le prix, l'**âge** le fait baisser.