

Combien vaut une voiture d'occasion ?

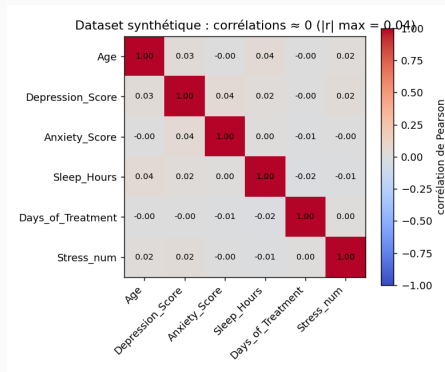
Introduction to Data Processing — MAM3, 2025-2026

Hafssa ■ Thibaud ■ Nathan

Université Côte d'Azur — Polytech Nice Sophia

Combien vaut votre voiture d'occasion ?


- Notre question : **peut-on prédire le prix d'une voiture d'occasion ?**
- 1^{er} essai : un dataset « santé mentale » (2 500 lignes) qui ne disait **rien** ($|r| \text{ max} \approx 0,04 \Rightarrow$ **synthétique**).
- Notre choix : un **vrai dataset** — **72 000 voitures** d'occasion (UK, 7 marques).
- Utile : estimer un prix juste, repérer les bonnes affaires, sites d'annonces.



Dataset synthétique : corrélations ≈ 0 .

72 000 voitures, 10 variables, un prix à prédire


- Source **réelle** UK Used Cars · **72 435 lignes** · **10 variables**.
- Cible : price, le prix en **livres £**.
- Numériques : année, kilométrage, taxe, conso, **cylindrée** ; catégorielles : modèle, boîte, carburant, marque.
- Nettoyage : années aberrantes (**2060, 1970**) + doublons → **71 593 lignes**.



2 indices maison à partir de l'année


Feature maison	Corr. prix
car_age (2026—année)	−0,52
mileage_per_year (km / âge)	−0,40

- car_age : plus une voiture est vieille, moins elle vaut.
- mileage_per_year : distingue une **vieille voiture peu roulée** d'une **récente très roulée**.



On prédit le prix à 74 % — et on corrige un vrai bug

- Régression **linéaire**, 5 variables, split **80-20**.
- R^2 (**test**) = **0,735** · R^2 (train) = 0,725 (pas de surapprentissage) · **RMSE** $\approx$ **4 800 £**.
- **Monte** le prix : cylindrée +10 862 £/L, boîte +480 £.
- **Baisse** le prix : âge -1 695 £/an, km/an -1,3 £.
- **Bug corrigé** : le code importait R^2 /RMSE mais ne les **calculait jamais**.



Des données réelles racontent une histoire — pas des données fabriquées

- Un modèle **simple** explique déjà **~74 %** du prix ; leviers clairs (cylindrée $\uparrow$, âge $\downarrow$).
- Nos features `car_age` / `mileage_per_year` portent l'effet du temps.
- Leçon : notre 1^{er} dataset (santé mentale) n'expliquait rien car **synthétique** (corrélations ≈ 0).
- Limites : catégories encodées en nombres (faux ordre), prix brut, marque/carburant non utilisés.
- Pistes : one-hot, modéliser $\log(\text{prix})$, ajouter marque & carburant, Ridge/Lasso.

Questions anticipées

- **Pourquoi linéaire ?** la cible (prix) est **continue** et on veut **interpréter** les coefficients (en £).
- **R^2 de 0,74, c'est bon ?** honnête pour un modèle simple ; et **train $\approx$ test** $\rightarrow$ pas de surapprentissage.
- **Pourquoi encoder model en nombre ?** solution **simple** pour un premier modèle ; limite assumée (faux ordre) $\rightarrow$ piste = one-hot.
- **Dispersion sur les voitures chères ?** la variance du prix augmente avec sa valeur ; piste = modéliser **log(prix)**.
- **Le vrai bug du code ?** il **importait** `r2_score` / `mean_squared_error` mais ne les utilisait jamais $\rightarrow$ la régression ne s'évaluait pas. Corrigé.
- **Données vraiment réelles ?** vraies annonces UK ; imperfections du réel (année 2060, doublons). Le 1^{er} dataset avait des corrélations ≈ 0 = signature du synthétique.

Merci !

**Des données *réelles* racontent une histoire.
Des données *fabriquées*, non.**