

Le stress se lit-il dans notre mode de vie ?


Introduction to Data Processing — MAM3, 2025-2026

Hafssa ■ Thibaud ■ Nathan

Université Côte d'Azur — Polytech Nice Sophia

Et si notre mode de vie trahissait notre stress ?


- Notre question : **quels facteurs du quotidien expliquent le stress ?**
- 1^{er} essai : un dataset « santé mentale » (2 500 lignes) qui ne disait **rien** ($|r|$ max $\approx 0,04 \Rightarrow$ **synthétique**).
- Notre choix : une **vraie enquête** bien-être — **15 971 personnes** (Authentic-Happiness).
- Utile : applis bien-être, prévention santé, qualité de vie au travail.



Dataset synthétique : corrélations ≈ 0 .

15 971 vies, 23 variables, un seul chiffre à expliquer


- Source **réelle** Authentic-Happiness · **15 971 lignes** · **23 variables**.
- Cible : DAILY_STRESS, score **0** → **5**.
- ~20 variables numériques (sommeil, vie sociale, méditation, congés non pris...) + 2 catégorielles (Âge, Genre).
- Nettoyage : 1 valeur cassée corrigée, **one-hot** Âge/Genre, **standardisation**.



4 indices maison — dont un qui nous a surpris


Feature maison	Corr. stress
OVERWORK (congé + irritab. – passions)	+0,35
HEALTHY_HABITS (sommeil+activité+médit.)	-0,22
SLEEP × FLOW (sommeil × immersion)	-0,16
SOCIAL_SUPPORT (entourage+réseau+entraide)	-0,06

- 3 marchent — surtout **OVERWORK**, meilleur signal de l'étude.
- **Pourquoi l'échec ?** réseau (+0,09) et entraide (+0,07) vont avec **plus** de stress $\Rightarrow$ ils annulent l'effet de l'entourage proche.



Le stress se lit dans nos habitudes — à 19 %

- Régression **linéaire**, split **80-20** + **5-fold**.
- R^2 (23 var) = **0,19** · R^2 (4 indices) = **0,13** · 5-fold = **0,14 ± 0,01** (stable).
- **Montent** : irritabilité **+0,32**, congés non pris **+0,18**.
- **Baissent** : méditation **−0,15**, sommeil **−0,13**, revenu suffisant **−0,12**, temps passions **−0,09**.



Des données réelles racontent une histoire — même quand elles nous contredisent

- Leviers **actionnables** : congés, méditation, sommeil, temps pour ses passions.
- Notre feature **OVERWORK** = meilleur prédicteur (+0,35).
- Un **échec** riche : SOCIAL_SUPPORT rappelle qu'une hypothèse se **vérifie** (corrélation $\neq$ intuition).
- Limites : auto-déclaré, échelle 0-5, **corrélation** $\neq$ **causalité**.
- Pistes : régression ordinale, revoir le soutien social, segmenter par âge.

Questions anticipées

- **Pourquoi linéaire et pas logistique ?** cible 0-5 continue + on veut **interpréter** les coefficients ; la logistique = piste d'amélioration.
- **R^2 de 0,19, c'est faible ?** le stress est multifactoriel et auto-déclaré ; un R^2 modéré est **honnête**. On vise l'explication. Le 5-fold ($\pm 0,01$) montre que c'est **stable**.
- **L'irritabilité (+0,32), n'est-ce pas circulaire ?** en partie : crier/bouder est aussi un *symptôme* du stress. D'où le levier **actionnable** = congés non pris.
- **Pourquoi garder une feature qui a échoué ?** pour montrer la **démarche** : l'échec de SOCIAL_SUPPORT nous a appris pourquoi (composantes contradictoires).
- **Données vraiment réelles ?** enquête identifiée + imperfections du réel ; le 1^{er} dataset avait des corrélations ≈ 0 = signature du synthétique.
- **Circularité du score ?** on a **retiré** WORK_LIFE_BALANCE_SCORE (somme des colonnes $\rightarrow R^2 = 1$ trompeur).

Merci !

**Des données *réelles* racontent une histoire.
Des données *fabriquées*, non.**